


МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ  
УНИВЕРСИТЕТ имени М. В. ЛОМОНОСОВА



Механико-математический факультет  
Кафедра математической теории интеллектуальных систем

Курсовая работа на тему  
«Прогнозирование изменения цен на  
российском рынке акций»  
«Forecasting price changes on the Russian  
stock market»

**Выполнил:**  
студент 309 группы  
кафедры математической теории интеллектуальных систем  
Дугин Максим Денисович

**Научный руководитель:**  
доцент кафедры  
математической теории интеллектуальных систем  
Боков Григорий Владимирович

Москва  
2024

# Содержание

<b>1. Введение</b>	<b>3</b>
<b>2. Постановка задачи</b>	<b>4</b>
<b>3. Обзор литературы</b>	<b>5</b>
3.1. Технический анализ . . . . .	5
3.2. Фундаментальный анализ . . . . .	5
3.3. Нейронные сети . . . . .	5
<b>4. Основные результаты</b>	<b>8</b>
4.1. Введение в нейронные сети . . . . .	8
4.2. Свёрточные нейронные сети . . . . .	9
4.3. Архитектура используемой нейронной сети . . . . .	11
4.4. Описание входных и выходных данных . . . . .	12
4.5. Описание написанного кода . . . . .	13
4.6. Сравнение результатов . . . . .	13
<b>5. Заключение</b>	<b>16</b>

# 1. Введение

Фондовый рынок имеет корни, уходящие в глубокую историю. Купля-продажа ценных бумаг стала обычной практикой еще в средние века, причем официальные биржи появились с XVI века. Начиная с Антверпена и Лиона, биржи стали местами для торговли акциями компаний.

В XIX и XX веках фондовые рынки подвергались воздействию различных экономических и социальных событий, которые сформировали их текущий облик. Кризисы, такие как Великая депрессия, выделяются среди таких событий, подчеркивая значимость стабильности и регулирования рынков.

В настоящее время фондовый рынок стал предметом повышенного интереса со стороны инвесторов и исследователей, благодаря его сложной и непредсказуемой природе. Развитие новых технологий и методов анализа, таких как машинное обучение и нейронные сети, демонстрирует новые возможности в области прогнозирования рынка акций.

Данная работа фокусируется на прогнозировании рынка акций с использованием нейронных сетей. Особое внимание уделяется изучению различных типов нейронных сетей и их применимости в анализе и прогнозировании изменений цен на акции. Кроме того, в работе анализируются потенциальные ограничения прогнозирования фондовых рынков при использовании нейронных сетей. Для более глубокого понимания этих ограничений проводится серия экспериментов с использованием данных российского фондового рынка.

## 2. Постановка задачи

Цель данного исследования заключается в изучении различных методов предсказания изменения цен на финансовых рынках, с акцентом на использование нейронных сетей. Конкретные задачи включают:

1) Обзор методов предсказания цен:

- Провести обзор существующих методов предсказания изменения цен на финансовых рынках, включая технический анализ, фундаментальный анализ и использование нейронных сетей.

2) Выбор и анализ нейронной сети:

- Выбрать подходящую архитектуру нейронной сети для прогнозирования изменения цен.

3) Подготовка данных и обучение модели:

- Собрать и подготовить данные о ценах на акции на российском рынке.
- Применить процедуры обучения и тестирования для выбранной нейронной сети.

4) Применение на российском рынке:

- Провести эксперименты с выбранной нейронной сетью, используя данные российского финансового рынка.
- Проанализировать результаты и оценить эффективность предсказаний.

5) Сравнение с другими странами:

- Произвести сравнительный анализ результатов работы нейронной сети на российском рынке с результатами на других рынках.

6) Выводы и рекомендации:

- Сделать обобщенные выводы об эффективности применения нейронных сетей для предсказания изменения цен.
- Предложить рекомендации для дальнейших исследований в данной области.

Это исследование будет ориентировано на практическое применение нейронных сетей для предсказания цен на российском финансовом рынке с акцентом на решение конкретных задач и выявление преимуществ и ограничений данного подхода.

### 3. Обзор литературы

Существует множество методов прогнозирования цен на акции. Некоторые работы уделяют внимание техническому анализу [1], который базируется на анализе графиков цен и объемов торгов, а также на использовании различных технических индикаторов (EMA, RSI, MACD). Другие подходы включают в себя фундаментальный анализ [2], который основан на анализе финансовой отчетности компаний и оценке их финансовой стабильности и перспектив. Кроме того, в последние годы стали активно использоваться алгоритмические методы и машинное обучение [3], включая генетические алгоритмы [4], метод опорных векторов [5] и ансамблирование моделей [6]. Среди всех типов машинного обучения стоит выделить нейронные сети, ведь он является одним из самых мощных и универсальных инструментов для анализа данных и решения различных задач. Такое разнообразие методов предоставляет исследователям и трейдерам широкие возможности для выбора наиболее подходящего подхода в зависимости от характера данных и целей прогнозирования.

Таким образом, можно выделить три самых популярных и масштабных варианта прогнозирования фондового рынка. Это технический анализ, фундаментальный анализ и использование нейронных сетей. Рассмотрим подробнее каждый из способов:

#### 3.1. Технический анализ

Эдвардс [1] является авторитетным источником в области технического анализа финансовых рынков. В книге исследуются методы анализа, основанные на графиках цен, с целью помочь трейдерам и инвесторам в прогнозировании изменения цен на рынке. Основные принципы технического анализа, включая тренды, поддержку и сопротивление, объем торгов, индикаторы и формации графиков, рассматриваются подробно на рисунке 3.1). Книга предоставляет практические советы и примеры для применения технического анализа на практике.

#### 3.2. Фундаментальный анализ

Абарбанель в своем исследовании [2] исследует фундаментальный анализ, метода оценки стоимости акций на основе фундаментальных характеристик компании (рис 3.2). Книга подробно рассматривает процесс фундаментального анализа, включая анализ финансовых отчетов и прогнозирование будущих доходов компании. Авторы делают выводы о том, как фундаментальный анализ влияет на цены на акции и как инвесторы могут использовать фундаментальные показатели для принятия инвестиционных решений.

#### 3.3. Нейронные сети

Среди разнообразных типов нейронных сетей, глубокие нейронные сети (ГНС) заслуживают особого внимания в контексте прогнозирования фондового рынка из-




Рис. 3.1: Примеры фигур технического анализа









Название, тикер	P / E	ROE	P / S	EPS	Рост EPS за 1 год	Рост EPS за 5 лет
 Газпром GAZP	3,01	12,89%	0,66	80,44 Р	+331,08%	-30,07%
 Роснефть ROSN	4,71	17,25%	0,53	92,95 Р	-39,48%	+40,33%
 НОВАТЭК NVTK	10,06	24,64%	3,81	144,2 Р	+255,58%	+11,05%
 ЛУКОЙЛ LKOH	5,03	17,91%	0,42	1,13 тыс. Р	+768,97%	+31,24%
 Газпром нефть SIBN	4,2	22,71%	0,69	106,71 Р	+79,71%	+20,26%
 Сургутнефтегаз SNGS	2,18	8,03%	0,81	11,35 Р	-65,13%	-0,49%
 Сургутнефтегаз - ... SNGSP	2,18	8,03%	0,81	11,35 Р	-65,13%	-0,49%
 Татнефть TATN	4,67	22,49%	0,74	88,14 Р	+117,43%	+13,16%

Рис. 3.2: Пример фундаментальных показателей

за их способности обрабатывать сложные нелинейные зависимости в данных. ГНС характеризуются большим количеством скрытых слоев и большим числом нейронов в каждом слое, что позволяет им выявлять сложные шаблоны и взаимосвязи, скрытые во входных данных.

Кроме того, ГНС обладают способностью автоматически извлекать признаки из данных на разных уровнях абстракции, что позволяет им эффективно моделировать различные аспекты поведения финансовых рынков. Это позволяет им адаптироваться к разнообразным условиям рынка и учитывать как краткосрочные, так и долгосрочные тенденции, что является важным фактором при прогнозировании динамики цен на акции.

Более того, ГНС обладают возможностью учитывать нелинейные взаимосвязи между различными факторами, такими как финансовые показатели компаний, макроэкономические индикаторы и изменения внешней среды. Это позволяет им улавливать тонкие закономерности и неочевидные взаимосвязи, которые могут быть незамеченными для более традиционных методов анализа.

Таким образом, глубокие нейронные сети представляют собой мощный инструмент для прогнозирования фондового рынка благодаря их способности обрабатывать сложные зависимости в данных, извлекать признаки на разных уровнях абстракции и учитывать нелинейные взаимосвязи между различными факторами.




Рис. 3.3: Пример глубокой нейронной сети

## 4. Основные результаты

Акцент основной цели данной работы сосредоточен на то, чтобы с помощью нейронной сети предсказывать движение акции на следующий период времени (вверх, вниз или нейтрально). Для достижения данной цели была взята свёрточная нейронная сеть и данные с Мосбиржи<sup>1</sup>. Но для начала было разобрано понятие нейронной сети с математической точки зрения, а также принцип работы свёрточных нейронных сетей в целом.

### 4.1. Введение в нейронные сети

Нейронные сети представляют собой комплексные математические модели, вдохновленные биологическими нейронными сетями, способные обрабатывать и анализировать данные. Принцип работы нейронных сетей основан на симуляции функционирования нейронов в человеческом мозге. Они состоят из множества взаимосвязанных и взаимодействующих между собой элементов, называемых нейронами, которые работают совместно для выполнения конкретной задачи.

Основными компонентами нейронных сетей являются нейроны, слои и веса.

Нейроны – это базовые блоки нейронной сети, которые принимают входные сигналы, их обрабатывают и передают дальше. У каждого нейрона есть конечное число входов и один выход. Как сказано в [12], за каждым входом закреплено некоторое вещественное число. Обозначим записью  $\omega_1, \dots, \omega_n$  список данных чисел (весов), соответствующих каждому из входов ( $\forall i = 1, \dots, n$  входу с номером  $i$  соответствует вес  $\omega_i$ ).

Кроме того, с нейроном связано число  $\omega_0 \geq 0$ , называемое порогом возбуждения. Все нейроны передают сигналы друг другу и у каждого сигнала есть своя интенсивность. Обозначим записью  $x^1, \dots, x^n$  список интенсивностей сигналов, поступивших в текущий момент по каждому из входов ( $\forall i = 1, \dots, n$   $x^i$  – интенсивность сигнала, поступившего на нейрон с номером  $i$ ). Суммарную взвешенную интенсивность всех сигналов можно записать как  $\sum_{i=1}^n x^i \omega_i$ , и

- если данная интенсивность превышает порог возбуждения нейрона  $\omega_0$ , то нейрон выпускает на выход сигнал некоторой интенсивности,
- иначе выходной сигнал не выпускается (мы будем считать, что в этом случае выпускается выходной сигнал нулевой интенсивности).

Таким образом, работу нейрона можно задать функцией  $f : (x^1, \dots, x^n) \rightarrow a$ , где  $a = \sum_{i=1}^n x^i \omega_i - \omega_0$ .

Далее нейроны группируются в слои (множество нейронов, собранных по их функциональному назначению). Существуют такие виды как входной слой, скрытые слои и выходной слой. Но для соединения всех слоёв нужно, чтобы выходы

---

<sup>1</sup><https://iss.moex.com/iss/reference/>



одних нейронов являлись входами для других. Можно заметить, что число  $a$  может быть отрицательным, а интенсивность, в свою очередь, не меньше нуля. С целью исправления этого от  $a$  берётся функция  $\sigma$ . Она может являться:

- индикатором луча  $I[0, +\infty) = \begin{cases} 0, & \text{при } x < 0 \\ 1, & \text{при } x \geq 0 \end{cases}$ ,
- сигмной:  $\sigma(x) = \frac{1}{1+e^{-x}}$ , или  $th(x)$ ,
- ReLU:  $\sigma(x) = \begin{cases} 0, & \text{при } x < 0 \\ x, & \text{при } x \geq 0 \end{cases}$


В данной работе используется свёрточная нейронная сеть (CNN). Давайте подробнее разберём этот вид.

## 4.2. Свёрточные нейронные сети


Свёрточные нейронные сети (CNN) – это тип компьютерных алгоритмов, используемых для работы с изображениями. Они пытаются понять, что находится на картинке и сделать предсказания на основе этого. Основная идея состоит в том, чтобы "пройтись" по изображению с помощью фильтров (математических операций, которые применяются к каждому пикселю изображения) для нахождения важных характеристик, таких как края или текстуры. Затем эти характеристики анализируются и используются для принятия решений. Значением, поступающим на вход, является набор закодированных пикселей изображения, представленный в виде матрицы  $(A = (a_{i,j})_{i=1,j=1}^{n,m})$ . Веса в CNN также записаны в виде матриц, обычно они более меньшего размера. Такие матрицы называются ядром.

Разберём пример на рисунке 4.1: Размер картинке 6 на 6 и каждый цвет закодирован своим числом. Будем считать, что чем больше число, тем ярче цвет. Картинку можно представить в виде матрицы 6 на 6 с целыми значениями  $(A = (a_{ij})_{i=1,j=1}^{6,6}, \forall i,j \quad a_{ij} \in \mathbb{Z})$ . Также есть ядро – матрица 3 на 3 с целыми значениями  $(B = (b_{ij})_{i=1,j=1}^{3,3}, \forall i,j \quad b_{ij} \in \mathbb{Z})$ . центром ядра является  $b_{22}$ . Далее ядро накладывается на исходную матрицу так, чтобы начало ядра лежало на первом элементе матрицы. И элементы ядра и матрицы  $A$  перемножаются между собой и складываются. Результат записывается в матрицу вывода  $C(c_{nm} = \sum_{i,j=0}^3 a_{(i-n)(j-m)} * b_{ij} = 9)$ . В итоге получаем матрицу, в которой более явно видно, где цвет более яркий.


Свёрточные слои - это этап обработки изображения, где алгоритм ищет различные формы и фигуры. После этого происходит этап пулинга (процесс уменьшения размерности изображения путем объединения информации из различных областей изображения), чтобы упростить их анализ. И наконец, данные проходят через полносвязные слои (часть нейронной сети, в которой каждый нейрон связан с каждым нейроном предыдущего и последующего слоев), которые делают окончательные выводы на основе полученных характеристик.




(a)



(b)



(c)



(d)

Рис. 4.1: Пример работы CNN

### 4.3. Архитектура используемой нейронной сети

Данная CNN была взята из работы [7].

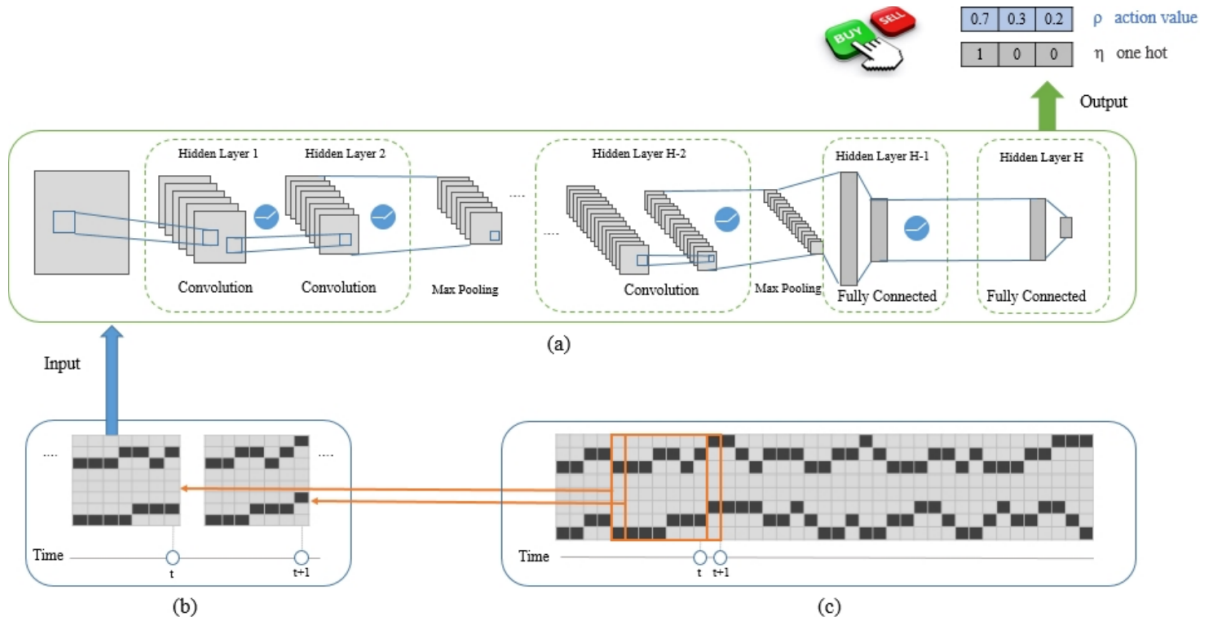


Рис. 4.2: Архитектура используемой нейронной сети

Архитектура этой свёрточной нейронной сети (CNN) представлена на 4.2 и используется в качестве аппроксиматора функции (математического объекта, приближающего некоторую неизвестную функцию). Наша CNN принимает на вход изображение графика в виде матрицы из 0 и 1 размером  $W$  на  $W$  и выдаёт два вектора длины 3: вектор ценности действий ( $\rho$ ) и one-hot вектор ( $\eta$ ). Три элемента каждого из векторов обозначают покупку, бездействие и продажу. Каждый элемент вектора  $\rho$  соответствует выгодности действия для данного входа. Вектор  $\eta$  содержит только один ненулевой элемент, у которого значение 1, соответствующей наибольшему значению в векторе  $\rho$ , и 0 в остальных позициях.

Точная архитектура данной CNN следующая. На вход поступает изображение размером 32x32 пикселя. Это означает, что на вход поступает матрица 32 на 32 из нулей и единиц. CNN состоит из шести скрытых слоев. Первые четыре скрытых слоя являются сверточными слоями, за которыми следует слой с функцией активации ReLU, которые преобразует каждый элемент матрицы в число от 0 до 1, а последние два слоя – полносвязанные. В полносвязных слоях функция ReLU применяется только после пятого слоя. Каждый из первых четырех скрытых слоев состоит из 16 фильтров размером 5x5x1, 16 фильтров размером 5x5x16, 32 фильтров размером 5x5x16 и 32 фильтров размером 5x5x32 соответственно, все с шагом 1, нулевым заполнением и последующим применением ReLU. После второго и четвертого скрытых слоев применяется операция сокращения размерности, называемая слоем максимального объединения. В этом слое используется фильтр размером 2x2 и шаг 2. Последние два скрытых слоя являются полносвязными и имеют парамет-

ры 2048x32 и 32x3 соответственно, за исключением последнего слоя, где функция активации ReLU не применяется. Каждый слой перед ReLU дополнительно содержит слой нормализации партии (метод в глубоком обучении, который нормализует входные данные, уравнивая их и делая более устойчивыми к изменениям в процессе обучения) [9]. Параметры инициализированы с использованием инициализации Ксавье [10].

#### 4.4. Описание входных и выходных данных

В данной работе используются данные с API мосбиржи <sup>1</sup>. Берутся цены закрытия 151-ой акции (отобраны по капитализации и актуальности данных) с периодом в 10 минут, далее они разбиваются на промежутки по 10 месяцев, на 9-ти из которых нейронная сеть тренируется, а на одном тестируется.

Входные данные состоят из двух частей: входного графика  $S_t$  и скалярного значения  $L_t$ . Нижний индекс  $t$  указывает на время.

Входной график  $S_t$  представляет собой матрицу размером 32 на 32, в которой все элементы либо 0, либо 1. Матрица 32 на 32 содержит данные о ценах закрытия и объемах торгов одной акции за 32 временных интервала. Например, входной график для дня  $t$  содержит данные о цене и объеме с  $(t-31)$ -го по  $t$ -ый период. На рисунке 4.2 показан пример входного графика размером 8 на 8. Один столбец представляет собой один временной промежуток. В верхней половине (на строках с 1 по 3) отображается относительное значение цены закрытия за 8 дней, а в нижней половине (на строках с 6 по 8) отображается относительное значение объема. Две строки в середине графика (в данном случае строки 4 и 5) заполнены нулями. Две строки посередине используются как разделители и помогают нашей свёрточной нейронной сети различать график цены и график объема. Значения цены и объема нормализуются по минимальному и максимальному значениям за 32 дня. Таким образом, наивысшие значения цены и объема отображаются в первой и шестой строках, соответственно, а самые низкие значения – в третьей и восьмой строках, соответственно.

$L_t$  – это скалярное значение, которое представляет собой процентное изменение цены от периода  $t$  к периоду  $t+1$ . Другими словами,  $L_t$  – это просто доходность компании с периода  $t$  на период  $t+1$ .

Для того, чтобы найти  $L_t$ , используется уравнение (4.1), где  $Prct$  – это цена закрытия в момент времени  $t$ .

$$L_t = \frac{Prct_{t+1} - Prct_t}{Prct_t} * 100 \quad (4.1)$$

На рисунке 4.2 график  $S_t$  показан как единственный вход нашей свёрточной нейронной сети, потому что скалярное значение  $L_t$  используется вместе с выходным значением нашей свёрточной нейронной сети для вычисления вознаграждения. Но на самом деле в процессе обучения/тестирования наша свёрточная нейронная сеть

---

<sup>1</sup><https://iss.moex.com/iss/reference/>

получает на вход матрицу размером 32 на 32 в период  $t$  в качестве входных данных  $S_t$  и выдает действие только на основе  $S_t$ .

## 4.5. Описание написанного кода

Основными результатами являются написанные программы.

Первая программа<sup>1</sup> используется для преобразования данных Московской биржи во входные данные для нейронной сети. О её особенностях можно узнать в самом коде.

Вторая программа<sup>2</sup> представляет собой реализацию свёрточной нейронной сети.

## 4.6. Сравнение результатов

Показателем того, что нейронная сеть обучается является график 4.3.



Рис. 4.3: Отклонение предсказания от действительной цены

По рисунку 4.4 можно понять, что в большинстве случаев нейронная сеть правильно прогнозировала изменение цены.

При сравнении результатов применения нейронной сети после проведения 6 миллионов итераций цикла с средней доходностью выбранных акций за этот период (см. рисунок 4.5), можно заметить удачный исход применения, так как доходность составила 23% за месяц при 1% у акций. Выбор действия на следующий период представляет собой неслучайное явление, и CNN способна выявлять закономерности в графиках цен акций. График доходности стабильно растёт и сильно не падает (максимальное падение =  $-1.1\%$ ), что означает нейронная сеть распознаёт паттерны для большинства ситуаций на рынке.

При сравнении результатов, полученных после применения нейронной сети после проведения 6 миллионов итераций цикла, со средней доходностью выбранных

<sup>1</sup>[https://github.com/MaksimDugin/CNN-for-MOEX/blob/main/scr/Parser\\_price.ipynb](https://github.com/MaksimDugin/CNN-for-MOEX/blob/main/scr/Parser_price.ipynb)

<sup>2</sup><https://github.com/MaksimDugin/CNN-for-MOEX/blob/main/scr/CNN.ipynb>

Процент положительных и отрицательных доходов




Рис. 4.4: Процент положительных и отрицательных доходов

акций за тот же период, можно увидеть значительные положительные изменения. Согласно рисунку 4.5, доходность, достигнутая за месяц, составила 23%, что существенно превосходит среднюю доходность выбранных акций, которая составила лишь 1%. Такой результат свидетельствует о том, что использование нейронной сети оказалось успешным.

Выбор действия на следующий период, сделанный нейронной сетью, указывает на его ненаслучайный характер, что предполагает способность CNN выявлять закономерности в графиках цен акций. График доходности демонстрирует устойчивый рост, характеризующийся минимальным падением. Максимальное снижение составило всего -1.1%, что свидетельствует о стабильности модели и её способности распознавать паттерны на рынке даже в условиях высокой волатильности.




Рис. 4.5: Сравнение результатов

Если сравнивать наши результаты средней доходности одной транзакции с результатами в [7], то мы добились доходности в размере 0.0737 процента за одну транзакцию при нейтральном портфеле, что ниже среднего результата в [7] (0.22). Мы полагаем, что это объясняется высокой волатильностью, что делает российский рынок менее предсказуемым. Но если брать страны, фондовый рынок которых похож на российский (Индия(0.01), Бразилия(0.12), Южная Корея(0.07), Турция(0.05)), то наши показатели будут либо сравнимы, либо превосходить вышеперечисленные.

## 5. Заключение

Можно выделить несколько ключевых результатов:

- Обзор методов предсказания изменения цен на финансовых рынках (раздел 3).
- Выбор подходящей нейронной сети для анализа цен (CNN) (раздел 4.2).
- Подготовка данных о ценах закрытия 151 акции (более 1 млн записей) (раздел 4.4).
- Преобразование данных и их разбиение на обучающие и тестовые (около 2 ГБ текстовых файлов) (раздел 4.5).
- Сравнение результатов с применением различных подходов (раздел 4.6).

Использование нейронных сетей для прогнозирования изменений цен на финансовых рынках, включая российский рынок, показывает высокую эффективность. Свёрточные нейронные сети хорошо справляются с анализом временных рядов и выявлением сложных закономерностей, что делает их полезными инструментами для трейдеров.

Для дальнейших исследований рекомендуется:

- **Улучшение архитектуры сети:** Оптимизация параметров и выбор различных типов сетей для прогнозирования.
- **Расширение базы данных:** Увеличение объема и разнообразия данных для обучения сети.
- **Изучение рисков и ограничений:** Исследование потенциальных рисков использования нейронных сетей для прогнозирования и разработка более надежных методов.



## Список литературы

- [1] Robert D Edwards, John Magee, and WH Charles Bassetti. *Technical analysis of stock trends*. CRC press, 2018.
- [2] Jeffrey S Abarbanell and Brian J Bushee. *Fundamental analysis, future earnings, and stock prices*. Accounting Research Center, Booth School of Business, University of Chicago, Wiley, 1997, vol. 35, pp. 1–24.
- [3] Shunrong Shen, Haomian Jiang, and Tongda Zhang. *Stock market forecasting using machine learning algorithms*. Department of Electrical Engineering, Stanford University, Stanford, CA, 2012, vol. 5, pp. 1–5.
- [4] Richard J Bauer. *Genetic algorithms and investment strategies*. John Wiley & Sons, 1994, vol. 19.
- [5] Wei Huang, Yoshiteru Nakamori, and Shou-Yang Wang. *Forecasting stock market movement direction with support vector machine*. Computers & Operations Research, Elsevier, 2005, vol. 32, pp. 2513–2522.
- [6] Isaac Kofi Nti, Adebayo Felix Adekoya, and Benjamin Asubam Weyri. *A comprehensive evaluation of ensemble learning for stock-market prediction*. Journal of Big Data, Springer, 2020, vol. 7, pp. 20.
- [7] J Lee, R Kim, Y Koh, and J Kang. *Global Stock Market Prediction Based on Stock Chart Images Using Deep Q-Network*. IEEE Access, 2019, vol. 7, pp. 167260–167277.
- [8] M U Gudelek, S A Boluk, and A M Ozbayoglu. *A deep learning based stock trading model with 2-D CNN trend detection*. 2017 IEEE Symposium Series on Computational Intelligence (SSCI), Honolulu, HI, USA, 2017, vol. 8, pp. 1–8.
- [9] S. Loffe and C. Szegedy. *Batch normalization: accelerating deep network training by reducing internal covariate shift*. ArXiv e-prints, 2015
- [10] X. Glorot and Y. Bengio. *Understanding the difficulty of training deep feedforward neural networks*. International conference on artificial intelligence and statistics, 2010, pp. 249–256.
- [11] Chaudhari I Thakkar. *A comprehensive survey on deep neural networks for stock market: The need, challenges, and future directions*. Expert Systems With Applications, United Kingdom, Pergamon Press Ltd., 2021, vol. 17, pp. 1–17.
- [12] А. Миронов. *Машинное обучение. Часть 1*. МАКС Пресс, 2018, pp. 4.